

웹 스크래핑 포트폴리오

한국폴리텍I대학 서울정수캠퍼스
인공지능소프트웨어과 하이테크과정
이재혁

2025. 12. 10 (수)

MLB 경기 예측을 위한 데이터 수집 웹

1. 프로젝트 개요

- 본 프로젝트는 MLB 경기 분석을 위한 투수·타자 데이터 자동 수집 시스템과 이를 시각적으로 비교하는 웹페이지 구축을 목표로 한 작업
- fangraphs.com에서 제공하는 데이터들을 수작업으로 수집하는 비효율적인 작업을 줄이기 위해 Python 기반의 동적 크롤링을 활용하여 MLB 데이터를 자동으로 수집하고 프론트엔드에서 실시간으로 조회하는 구조를 설계·구현

2. 데이터 수집 방식

- 웹페이지에서 날짜, 경기, 선발투수 선택 → Selenium으로 실제 크롬 브라우저 실행 → Fangraphs URL 접속 (선택된 날짜에 따라 주소가 달라지도록 설정) → 데이터가 화면에 모두 채워질 때까지 대기 (3~8초 임의의 대기시간 설정) → 완성된 표의 HTML 구조 확보 → 데이터를 추출하여 JSON 파일 및 DB에 저장 (이후 동일 날짜의 경기들은 DB에 저장되어 재사용 가능) → 웹페이지에 데이터 표시 및 비교 그래프로 시각화

3. 시스템 구성 요약

- Frontend
 - HTML,CSS 사용으로 웹페이지 구성
 - JavaScript로 경기 일정, 선발투수 목록, 백엔드와 통신 및 테이블과 차트로 표시 파일 구성
- Backend
 - 프로그래밍 언어 : python 3.12
 - Selenium : 웹 브라우저 자동화
 - Undetected_chromedriver : Cloudflare 봇 탐지 우회
 - BeautifulSoup : HTML 파싱

4. 주요 성과

- MLB 선수 최근 기록을 날짜 범위 기반으로 자동 수집하는 기능 확보
- Cloudflare 봇 탐지 우회로 안정적인 크롤링 환경 확보
- 수집 데이터를 DB·JSON으로 저장하여 재사용성을 높이는 구조 구축

5. 결과 화면

